Video Coding for Machine Vision Applications

Τσάκα Έλενα, Ανδρέας Παναγόπουλος

A.M. 2122066, email: etsaka@uth.gr
A.M. 2122038, email: anpanagopoulos@uth.gr

Abstract

Στην παρούσα εργασία μελετώνται τεχνικές συμπίεσης εικόνας με χρήση προεκπαιδευμένων μοντέλων της βιβλιοθήκης CompressAI. Ακολούθησε σταθερή διαδικασία προεπεξεργασίας και κοινό σύνολο επιπέδων ποιότητας ώστε τα αποτελέσματα και οι συγκρίσεις να εξεταστούν υπό τις ίδιες συνθήκες. Για κάθε μέθοδο επιλέχθηκαν μετρήσεις bpp, PSNR, MS-SSIM καθώς και χρόνοι κωδικοποίησης και αποκωδικοποίησης μνήμης. Οι παραγόμενες καμπύλες RD, δηλαδή τα αποτελέσματα, αναδεικνύουν τα πλεονεκτήματα και τις αδυναμίες του εκάστοτε μοντέλου.

Εισαγωγή

Η ταχεία αύξηση του όγκου οπτικών δεδομένων καθιστά απαραίτητη την ύπαρξη αποδοτικής συμπίεσης και επεξεργασίας που είναι αφενός αποδοτική προς το μέγεθος και αφετέρου συμβατή με τις ανάγκες των σύγχρονων αναγκών. Η κλασσική συμπίεση στοχεύει στη διατήρηση της ποιότητας όπως γίνεται αντιληπτή από τους ανθρώπους όμως οι σύγχρονες εφαρμογές απαιτούν μοντέλα που προστατεύουν πληροφορίες που αξιοποιούν οι αλγόριθμοι. Αυτή η αλλαγή αναγκών δημιουργεί νέες απαιτήσεις.

Η συγκεκριμένη εργασία επικεντρώνεται στην συμπίεση εικόνας και στην αξιολόγηση της απόδοσης διαφόρων μοντέλων της βιβλιοθήκης CompressAI. Μάλιστα η μελέτη εξετάζει τις σχέσεις ρυθμού/παραμόρφωσης (Rate/Distortion,RD) χρησιμοποιώντας ως βασικούς δείκτες τα bits per pixel (bpp), PSNR και MS-SSIM.

Τα ζητούμενα που χρειάστηκε να ικανοποιήσουμε στην παρούσα εργασία είναι τα παρακάτω :

- Διαμόρφωση ενός συνεπούς και αναπαραγωγικού πρωτοκόλλου αξιολόγησης, με ενιαία επεξεργασία δεδομένων και κοινό quality ladder.
- Συστηματική σύγκριση τεσσάρων learned compression μοντέλων με έμφαση στις σχέσεις ρυθμού/παραμόρφωσης.
- Οργάνωση όλων των μετρήσεων σε τυποποιημένα CSV αρχεία συνοδευόμενα από αυτοματοποιημένα scripts παραγωγής RD καμπυλών.
- Συλλογή και ανάλυση υπολογιστικών μετρικών, συμβάλλοντας στη μελέτη της πρακτικής χρήσης των μοντέλων.

Η δομή της αναφοράς περιλαμβάνει το θεωρητικό υπόβαθρο, τη μεθοδολογία και τα δεδομένα, την πειραματική διαδικασία και τα αποτελέσματα και τέλος παρατίθεται η αξιολόγηση και τα συμπεράσματα.

Θεωρητικό Υπόβαθρο

Η κλασσική συμπίεση εικόνας και βίντεο βασίζεται σε μία σειρά από διαδοχικά στάδια τα οποία έχουν σχεδιαστεί ώστε να εκμεταλλεύονται τις στατιστικές ιδιότητες των οπτικών δεδομένων. Τα πρότυπα όπως vvc και jpeg εμφανίζουν παραλλαγές των ίδιων βασικών μηχανισμών.

1. Prediction. Ο encoder προσπαθεί να προβλέψει την τιμή των pixel ή των blocks. Συγκεκριμένα στην περίπτωση εικόνας εφαρμόζεται intra prediction, όπου κάθε block προβλέπεται σε σχέση με τα γειτονικά του. Δε περίπτωση βίντεο χρησιμοποιείται και inter prediction, αξιοποιώντας την κίνηση μεταξύ διαφορετικών clips.
2. Transforms. Το residual μετατρέπεται σε μια αναπαράσταση μέσω μετασχηματισμών όπως ο Discrete Cosine Transformation DCT ή ο Discrete Sine Transformation DST. Μέσω των μετασχηματισμών συγκεντρώνουν την ενέργεια του σήματος σε λίγους συντελεστές επιτρέποντας αποτελεσματικότερη κωδικοποίηση.
3. Quantization. Μετά τον μετασχηματισμό, οι συντελεστές, περνάνε από ποσοτικοποίηση δηλαδή στρογγυλοποίηση σε ένα περιορισμένο σύνολο τιμών. Αυτό είναι ένα στάδιο το οποίο εισάγει απώλεια πληροφορίας.
4. Entropy. Τέλος, οι ποσοτικοποιημένοι συντελεστές κωδικοποιούνται με αλγορίθμους όπως Huffman, CABAC κλπ. Η χρήση συχνοτήτων και πιθανοτήτων επιτρέπει την επίτευξη ενός συμπιεσμένου bitstream χωρίς περαιτέρω απώλεια ποιότητας.

Το learned image compression σε αντίθεση με την κλασική συμπίεση υλοποιείται από ένα ενιαίο end to end νευρωνικό μοντέλο. Συνήθως χρησιμοποιούνται autoencoders, με έναν encoder που συμπιέζει την εικόνα σε λιγότερα χαρακτηριστικά, ο decoder την ανασκευάζει και ενδιάμεσα υπάρχει ένα entropy model το οποίο προσπαθεί να προβλέψει πόσα bits χρειάζονται για κάθε συγκεντρωμένη πληροφορία.
Τα μοντέλα της βιβλιοθήκης CompressAI υλοποιούν πολλές αρχιτεκτονικές τους όπως το bmshj2018, mbt2018 κ.α.

Το πρότυπο VVC αποτελεί ένα από τα ανερχόμενα πρότυπα συμπίεσης βίντεο, ώς διαδοχικό του HEVC. Σχεδιάστηκε για εφαρμογές υψηλής ανάλυσης, όπως 4K και 8K, και προσφέρει σημαντική μείωση bitrate σε σχέση με προηγούμενα πρότυπα. Λόγω της

υψηλής αποδοτικότητας του το VVC χρησιμοποιείται συχνά ως benchmark στην αξιολόγηση σύγχρονων μεθόδων συμπίεσης.
Η υλοποίηση UVG266 αποτελεί πρακτικό encoder βασισμένο στο VVC και χρησιμοποιείται ευρέως σε πειράματα λόγω της σταθερότητας και της ευκολίας παραμετροποίησης του.

Τα παραδοσιακά video codecs στοχεύουν στη βελτιστοποίηση του Rate Distortion με βάση ανθρώπινες μετρικές. Αντιθέτως τα πλαίσια VCM και FCM εστιάζουν στη βελτιστοποίηση της πληροφορίας που απαιτείται από ένα downstream machine learning task. Ο encoder μπορεί να προσαρμοστεί ώστε να διατηρεί τις υψηλές σημασίας περιοχές για το δίκτυο, οδηγώντας σε αποδοτικότερη χρήση του bitrate.
Εκεί η αξιολόγηση γίνεται με καμπύλες accuracy-rate. Βλέπουμε δηλαδή την ακρίβεια που κρατά το σύστημα σε διαφορετικά bitrates. Συχνά μια εικόνα που φαίνεται υποβαθμισμένη στον άνθρωπο να είναι απολύτως επαρκής αν διατηρεί κατάλληλες δομές και χαρακτηριστικά που χρειάζεται το μοντέλο. Τα συστήματα αυτά χρησιμοποιούνται σε εφαρμογές όπως έξυπνες κάμερες, αυτόνομη οδήγηση κλπ. όπου προτεραιότητα έχει η αξιοπιστία των αλγορίθμων και όχι η αισθητική ποιότητα.

Δεδομένα και Προεπεξεργασία

Για την αξιολόγηση χρησιμοποιήθηκε το σύνολο εικόνων Kodak (kodim01-24.png), το οποίο περιλαμβάνει 24 υψηλής ποιότητας εικόνες ευρέως φάσματος περιεχομένου. Το dataset υπέστη ενιαία προεπεξεργασία μέσω του script preprocess.py το οποίο εφαρμόζει ανακλιμάκωση με διατήρηση αναλογιών ώστε η μέγιστη διάσταση να γίνει 768 pixels και στη συνέχεια εφαρμόστηκε κεντρικό αποκομμα 512x512. Τέλος, αποθηκεύτηκαν οι εικόνες σε μορφή .png προκειμένου να αποφευχθούν ανεπιθύμητες αλλοιώσεις πριν την κωδικοποίηση.

Μεθοδολογία και Πρωτόκολλο

Για την σύγκριση των μοντέλων χρησιμοποιήθηκε κοινό quality ladder αποτελούμενο από πέντε διακριτά σημεία ποιότητας. Συγκεκριμένα χρησιμοποιήθηκαν τα σημεία {2 ,3 ,4 ,5 ,6} τα οποία αντιστοιχούν στις προκαθορισμένες ρυθμίσεις ποιότητας των προεκπαιδευμένων μοντέλων της CompressAI. Συγκεκριμένα κάθε τιμή q ενεργοποιεί διαφορετικά quantization step sizes & entropy model parameters, επηρεάζοντας το trade off μεταξύ bitrate και ποιότητας ανακατασκευής. Χαμηλά επίπεδα (q=2) εφαρμόζουν ισχυρή ποσοτικοποίηση με αποτέλεσμα χαμηλό bitrate και μεγαλύτερη παραμόρφωση, ενώ υψηλότερα επίπεδα (π.χ. q=6) χρησιμοποιούν πιο λεπτή ποσοτικοποίηση αυξανοντας την πιστότητα αλλά και το απαιτούμενο bitrate. Η χρήση των ενιαίων τιμών q για όλα τα μοντέλα εξασφαλίζει ότι οι RD καμπύλες είναι άμεσα συγκρίσιμες, καθώς όλα τα συστήματα αξιολογούνται υπό το ίδιο σύνολο ποιοτικών επιπέδων.

Για να διασφαλιστεί η δίκαιη και αξιόπιστη σύγκριση μεταξύ μοντέλων υιοθετήθηκαν συγκεκριμένοι κανόνες ισοτιμίας σε όλα τα πειράματα. Πρώτον, όλα τα μοντέλα αξιολογήθηκαν στο ίδιο σύνολο εικόνων, χωρίς καμία διαφοροποίηση μεταξύ τους. Δεύτερον, εφαρμόστηκε απόλυτα κοινή πολιτική προεπεξεργασιας, καθώς κάθε εικόνα πέρασε από ενιαίο resize στη μεγαλύτερη διάσταση των 768 pixels και center crop 512x512 μέσω του ίδιου script. Αυτή η επιλογή διασφαλίζει ότι οι διάφορες μετρικές προέρχονται αυστηρά από τις ίδιες τις αρχιτεκτονικές και όχι από μεταβολές στα δεδομένα εισόδου.

Επιπλέον, για την πλήρη αναπαραγωγή των αποτελεσμάτων, πραγματοποιήθηκε version locking των εργαλείων και βιβλιοθηκών που χρησιμοποιήθηκαν στο πείραμα.
Όλες οι δοκιμές εκτελέστηκαν με τις ίδιες εκδόσεις Python, PyTorch, CompressAI και των σχετικών εξαρτήσεων, έτσι ώστε η συμπεριφορά των μοντέλων να παραμείνει σταθερή σε όλες τις διαφορετικές εκτελέσεις. Με τον τρόπο αυτόν, τα αποτελέσματα των RD καμπυλών αντανακλούν αποκλειστικά την απόδοση των codec και όχι αστάθειες ή αλλαγές λογισμικού.

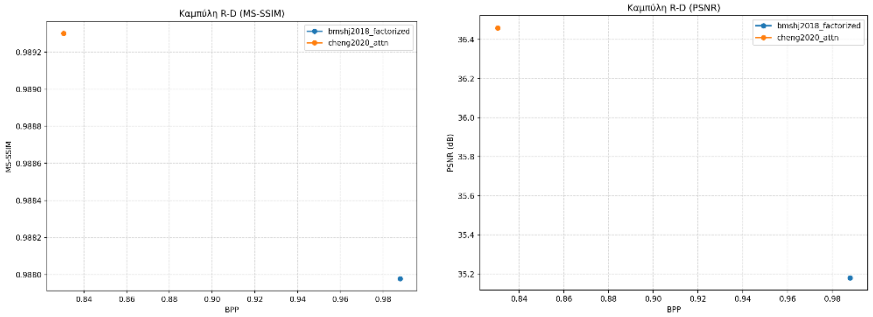
Για την αξιολόγηση των διαφορετικών μοντέλων συμπίεσης χρησιμοποιήθηκε ένα σύνολο καθιερωμένων μετρικών, οι οποίες επιτρέπουν τη συστηματική και αντικειμενική σύγκριση των αποτελεσμάτων. Συγκεκριμένα οι μετρικές που χρησιμοποιήθηκαν για το υποχρεωτικό σκέλος είναι οι εξής. Αρχικά bits per pixel (bpp), οπού εκφράζει το τελικό μέγεθος του συμπιεσμένου bitstream ανά pixel. Πρόκειται για άμεσο μέτρο του bitrate και επιτρέπει τη σύγκριση της αποτελεσματικότητας της συμπίεσης μεταξύ διαφορετικών μοντέλων. Χαμηλότερο bpp σημαίνει ισχυρότερη συμπίεση. Ύστερα, PSNR το οποίο μετρά τη διαφορά μεταξύ της αρχικής και της επεξεργασμένης εικόνας. Υψηλότερο PSNR υποδηλώνει μεγαλύτερη ομοιότητα και μικρότερη παραμόρφωση. Τέλος, το MS-SSIM το οποίο μοντελοποιεί τη δομική ομοιότητα ανάμεσα σε δύο εικόνες σε πολλαπλές κλίμακες. Το μοντέλο αυτό σχετίζεται καλύτερα με την ανθρώπινη αντίληψη της ποιότητας, ενώ το PSNR εκφράζει αποκλειστικά το μαθηματικό σφάλμα.

Οι τρείς μετρικές αυτές επιτρέπουν την κατασκευή των καμπυλών, οι οποίες αποτελούν τον κύριο τρόπο σύγκρισης μεταξύ των προεκπαιδευμένων μοντέλων της CompressAI.

Όλες οι μετρήσεις της εργασίας αποθηκεύτηκαν σε αρχεία CSV, ώστε τα αποτελέσματα να είναι οργανωμένα και αναγνώσιμα. Το βασικό αρχείου εξόδου παράγεται από το compress_rd.py ,μάλιστα παράγει το αρχείο results_rd_curve_kodak.csv με τις κατηγορίες : img, model, level, bpp, psnr, ms_ssim, enc_time, dec_time, mem.
Για το προαιρετικό μέρος του Bonus 2 δημιουργείται το bonus2.csv με κεφαλίδες: model, level, enc_time, dec_time, mem.

Για την ανάλυση Ablation συγκρίθηκαν τα μοντέλα bmshj2018_factorized & cheng2020_attn υπό κοινές συνθήκες συμπίεσης στο επίπεδο ποιότητας Q=6, με

σταθερά όλα τα υπόλοιπα στοιχεία του πρωτοκόλλου (dataset, preprocessing, metrics). Η σύγκριση βασίστηκε στις RD καμπύλες PSNR-BPP & MS-SSIM-BPP.
Τα αποτελέσματα δείχνουν ότι το cheng2020_attn παρουσιάζει υψηλότερο PSNR και υψηλότερο MS-SSIM σε σχέση με το bmshj2018_factorized ενώ ταυτόχρονα επιτυγχάνει χαμηλότερο BPP.



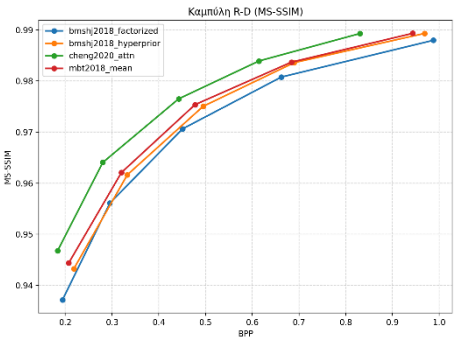
Αυτό μας υποδεικνύει ότι το cheng2020_attn ως attention-based hyperprior μοντέλο, βελτιώνει την ακρίβεια στην ανακατασκευή της εικόνας εισόδου. Ο αριθμός των παραμέτρων είναι σαφώς μεγαλύτερος, γι αυτό και έχουμε αντιστάθμιση μεταξύ πολυπλοκότητας και ποιότητας.

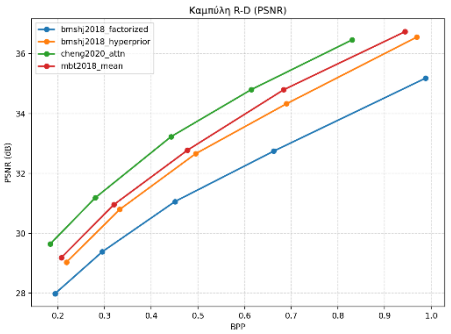
(1)

Εκτέλεση

Τα πειράματα εκτελέστηκαν σε περιβάλλον Ubuntu WSL (Windows Subsystem for Linux) σε σύστημα επεξεργαστή Intel 12th Generation Core i5-12400 (2.5 GHz). Οι κύριες εκδόσεις των βιβλιοθηκών που χρησιμοποιήθηκαν ήταν οι PyTorch: 2.8.0+cpu & CompressAI: 1.2.8.

Η υλοποίηση οργανώθηκε σε διακριτά scripts. Αναλυτικότερα, το preprocess.py εκτελεί την ενιαία διαδικασία προεπεξεργασιας των εικόνων. Ύστερα το compress.py αποτελεί το κεντρικό script αξιολόγησης καθώς υπολογίζονται οι μετρικές BPP, PSNR, MS-SSIM καθώς και τους χρόνους enc_time & dec_time. Σε συνέχεια το plot_rd.py αναλύει τα περιεχόμενα του αρχείου CSV που δημιουργεί το compress.py, και παράγει τις καμπύλες Rate-Distortion για όλες τις αρχιτεκτονικές. Στο προαιρετικό κομμάτι το bonus2.py συλλέγει υπολογιστικές μετρήσεις για κάθε επίπεδο ποιότητας παράγοντας ξεχωριστό CSV και το bonus2_plot.py δημιουργεί τα διαγράμματα που απεικονίζουν τον χρόνο κωδικοποίησης και αποκωδικοποίησης ανά μοντέλο και επίπεδο ποιότητας.





Για την εικόνα αυτή το table είναι :



model	level	bpp	psnr	ms_ssim	enc_time	dec_time
cheng2020_attn	2	0.1967	28.69	0.9336	1.0607	2.7717
cheng2020_attn	3	0.3044	30.21	0.9541	1.0458	2.7638
cheng2020_attn	4	0.4873	32.35	0.9711	2.1499	3.3821
cheng2020_attn	5	0.6857	34.02	0.9812	1.8237	3.9122
cheng2020_attn	6	0.9507	35.85	0.9887	1.8151	4.3094
bmshj2018_factorized	2	0.1998	26.98	0.9262	0.1005	0.1185
bmshj2018_factorized	3	0.3083	28.32	0.9484	0.0956	0.1289
bmshj2018_factorized	4	0.4797	29.97	0.9665	0.0961	0.1205
bmshj2018_factorized	5	0.7155	31.67	0.9789	0.0864	0.1219
bmshj2018_factorized	6	1.0852	34.35	0.9873	0.161	0.2376
bmshj2018_hyperprior	2	0.2311	28.14	0.9312	0.1056	0.1352
bmshj2018_hyperprior	3	0.3602	29.89	0.9543	0.1056	0.1353
bmshj2018_hyperprior	4	0.5431	31.82	0.9711	0.1126	0.115
bmshj2018_hyperprior	5	0.7716	33.55	0.9824	0.1119	0.1342
bmshj2018_hyperprior	6	1.1012	36.12	0.9896	0.2045	0.2609
mbt2018_mean	2	0.2205	28.23	0.9321	0.1242	0.1393
mbt2018_mean	3	0.3463	30.03	0.9533	0.1122	0.1344
mbt2018_mean	4	0.5245	31.91	0.9709	0.1209	0.137
mbt2018_mean	5	0.7614	34.12	0.9819	0.2367	0.2763
mbt2018_mean	6	1.0634	36.27	0.9892	0.2245	0.2756

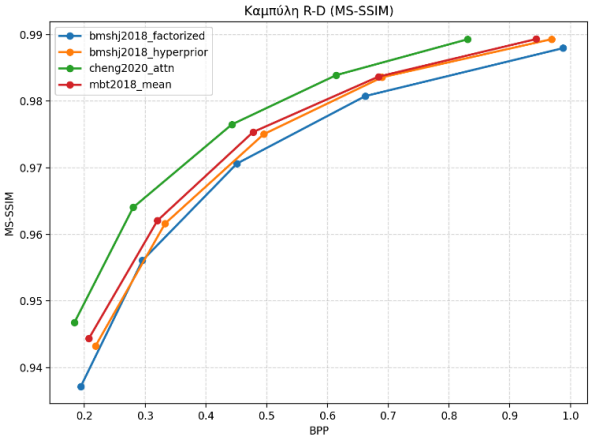
Οργάνωση Πειραμάτων

Στο Track A αξιολογήθηκαν τέσσερις αρχιτεκτονικές της CompressAI: bmshj2018_factorized, bmshj2018_hyperprior, mbt2018_mean και cheng2020_attn. Για κάθε εικόνα και κάθε quality level υπολογίζονται αυτόματα οι μετρικές bitrate(bpp), PSNR & MS-SSIM ενώ καταγράφονται επιπλέον ο χρόνος κωδικοποίησης και αποκωδικοποίησης και η χρήση μνήμης μοντέλου.

Στο Track C αξιολογήθηκε η υπολογιστική πολυπλοκότητα μοντέλων μέσω του Bonus2. Για κάθε αρχιτεκτονική και επίπεδο ποιότητας μετρήθηκαν και εδώ ο χρόνος κωδικοποίησης, ο χρόνος αποκωδικοποίησης και η χρήση μνήμης. Τα δεδομένα καταγράφηκαν σε ξεχωριστό αρχείο CSV και οπτικοποιήθηκαν με rate vs time plots, τα οποία παρουσιάζουν το πως αυξάνονται οι απαιτήσεις εκτέλεσης καθώς ανεβαίνει η ποιότητα. Η ανάλυση αυτή αναδεικνύει τα trade-offs ανάμεσα σε ποιότητα συμπίεσης και υπολογιστικό φορτίο. Μάλιστα τα πιο σύνθετα μοντέλα προσφέρουν υψηλότερη ποιότητα, αλλά απαιτούν μεγαλύτερο χρόνο επεξεργασίας.

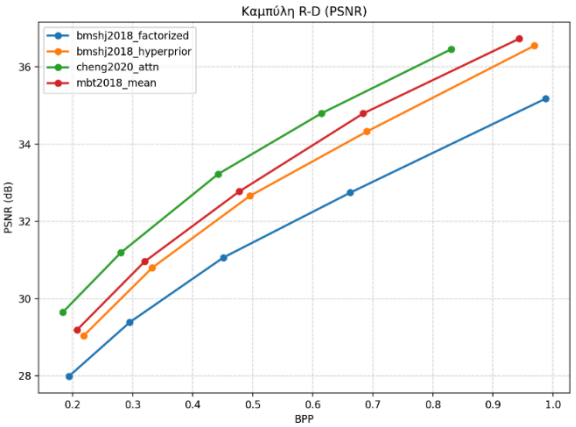
Αποτελέσματα

Στο παρόν τμήμα παρουσιάζονται τα αποτελέσματα της αξιολόγησης της συμπίεσης εικόνας για τα τέσσερα μοντέλα της βιβλιοθήκης CompressAI. Οι μετρικές και τα διαγράμματα προέρχονται από το ενιαίο CSV αρχείο που δημιουργήθηκε από το script compress_rd.py:



Η παραπάνω καμπύλη παρουσιάζει την σχέση ανάμεσα στο Bitrate και στη μετρική MS-SSIM. Παρατηρείται ότι στην σταθερή κλίμακα ποιότητας, το cheng2020_attn επιτυγχάνει συστηματικά υψηλότερο MS-SSIM για δεδομένο BPP ενώ το bmshj2018_factorized αποδίδει χαμηλότερα όπως αναμένεται από την απλούστερη

αρχιτεκτονική του. Επιπλέον το mbt2018_mean καθώς και το bmshj2018_hyperprior αποδίδουν παρομοιότυπα αποτελέσματα μεταξύ τους.



Η καμπύλη απεικονίζει τη μεταβολή του PSNR ως συνάρτηση του bitrate. Και εδώ παρατηρείται το cheng2020_attn το οποίο υπερέχει στο σύνολο των επιπέδων ποιότητας, ενώ τα μοντέλα bmshj2018_hyperprior & mbt2018_mean εμφανίζουν ενδιάμεση απόδοση. Το bmshj2018_factorized αποτελεί τη χαμηλότερη γραμμή βάσης.

Οι καμπύλες συνολικά επιβεβαιώνουν ότι πιο σύνθετές αρχιτεκτονικές με attention και βελτιωμένα entropy models επιτυγχάνουν υψηλότερη ποιότητα ανακατασκευής για ίδιο bitrate.

Για να υποστηριχθεί η ποσοτική αξιολόγηση των μοντέλων, παρατίθεται πίνακας με τις μετρικές BPP, PSNR, MS-SSIM και τους χρόνους κωδικοποίησης/αποκωδικοποίησης για όλα τα επίπεδα ποιότητας. Ο πίνακας προέρχεται απευθείας από το αρχείο CSV που παράγεται αυτόματα από την υλοποίηση.

model	level	bpp	psnr	ms_ssim	enc_time	dec_time
cheng2020_attn	2	0.1967	28.69	0.9336	1.0607	2.7717
cheng2020_attn	3	0.3044	30.21	0.9541	1.0458	2.7638
cheng2020_attn	4	0.4873	32.35	0.9711	2.1499	3.3821
cheng2020_attn	5	0.6857	34.02	0.9812	1.8237	3.9122
cheng2020_attn	6	0.9507	35.85	0.9887	1.8151	4.3094
bmshj2018_factorized	2	0.1998	26.98	0.9262	0.1005	0.1185
bmshj2018_factorized	3	0.3083	28.32	0.9484	0.0956	0.1289
bmshj2018_factorized	4	0.4797	29.97	0.9665	0.0961	0.1205
bmshj2018_factorized	5	0.7155	31.67	0.9789	0.0864	0.1219
bmshj2018_factorized	6	1.0852	34.35	0.9873	0.161	0.2376
bmshj2018_hyperprior	2	0.2311	28.14	0.9312	0.1056	0.1352
bmshj2018_hyperprior	3	0.3602	29.89	0.9543	0.1056	0.1353
bmshj2018_hyperprior	4	0.5431	31.82	0.9711	0.1126	0.115
bmshj2018_hyperprior	5	0.7716	33.55	0.9824	0.1119	0.1342
bmshj2018_hyperprior	6	1.1012	36.12	0.9896	0.2045	0.2609
mbt2018_mean	2	0.2205	28.23	0.9321	0.1242	0.1393
mbt2018_mean	3	0.3463	30.03	0.9533	0.1122	0.1344
mbt2018_mean	4	0.5245	31.91	0.9709	0.1209	0.137
mbt2018_mean	5	0.7614	34.12	0.9819	0.2367	0.2763
mbt2018_mean	6	1.0634	36.27	0.9892	0.2245	0.2756

Συζήτηση

Τα αποτελέσματα δείχνουν ότι το cheng2020_attn υπερέχει συστηματικά σε όλα τα bitrates, καθώς και ο μηχανισμός attention επιτρέπει πιο αποτελεσματική κατανομή bits σε περιοχές με υψηλή πληροφοριακή πυκνότητα. Αντίθετα το bmshj2018_factorized παρουσιάζει χαμηλότερη απόδοση, επειδή στηρίζεται σε ένα απλό factorized entropy model, το οποίο δεν μπορεί να συλλάβει την πραγματική συσχέτιση των latent coefficients. Ως αποτέλεσμα το μοντέλο δυσκολεύεται να αναπαραστήσει περίπλοκες υφές και λεπτές δομές, οδηγώντας σε χαμηλότερο PSNR και MS-SSIM. Τα bmshj2018_hyperprior & mbt2018_mean τοποθετούνται ενδιάμεσα. Το hyperprior ωφελείται από το επιπλέον side information που επιτρέπει πιο ακριβή μοντέλα της κατανομής latent, γεγονός που βοηθάει ιδιαίτερα σε χαμηλά bitrates, όπου η επίβλεψη της variance είναι καθοριστική. Το mbt2018_mean συχνά το πλησιάζει (ή και ξεπερνά) σε υψηλότερες ποιότητες όπου η διαθεσιμότητα περισσότερων bits μειώνει τη σημασία του side information και ευνοεί αρχιτεκτονικές με καλύτερο capacity στο decoder.

Αφενός έχουμε καθαρά αποτελέσματα, αφετέρου η μελέτη παρουσιάζει κάποιους περιορισμούς που επηρεάζουν τα συμπεράσματα. Αρχικά, η αξιολόγηση βασίστηκε αποκλειστικά στο Kodak dataset, το οποίο περιλαμβάνει μόλις 24 εικόνες περιορισμένης ποικιλίας. Ως αποτέλεσμα δεν καλύπτεται πλήρως η στατιστική μεταβολή που εμφανίζεται σε πραγματικά datasets με μεγαλύτερη ετερογένεια σε υφές, φωτισμό και περιεχόμενο. Τέλος, η εργασία εκτελέστηκε σε CPU μέσω WSL, γεγονός που μπορεί να επηρεάσει

τους χρόνους κωδικοποίησης και αποκωδικοποίησης. Η απόδοση μοντέλων, ειδικά των πιο σύνθετων (π.χ. cheng2020_attn) ενδέχεται να διαφέρει σημαντικά σε native Linux Ή GPU περιβάλλοντα, όπου η παράλληλη επεξεργασία αλλάζει δραστικά το computational profile. Συνεπώς οι absolute timings δε πρέπει να θεωρηθούν απόλυτα αντιπροσωπευτικοί.

Για μελλοντική επέκταση, θα μπορούσαμε να εστιάσουμε σε πιο ολοκληρωμένη και ρεαλιστική αξιολόγηση των μοντέλων τόσο στη μεθοδολογία όσο και στο εύρος των δεδομένων. Η χρήση μεγαλύτερων και ποικιλόμορφων datasets (π.χ. DIV2K) θα επέτρεπε ακριβέστερη στατιστική ανάλυση και αξιολόγηση σε πιο απαιτητικές υφές και υψηλές αναλύσεις. Επιπλέον βοήθεια στη διερεύνηση νέων τάσεων στο χώρο της learned compression, θα δημιουργούσε η σύγκριση με πιο σύγχρονες αρχιτεκτονικές. Επιπρόσθετα η αξιοποίηση GPU acceleration ή mixed-precision εκτέλεσης θα επέτρεπε πιο ρεαλιστική εκτίμηση χρόνων και καλύτερη κατανόηση του υπολογιστικού κόστους. Τέλος, η ενσωμάτωση πρόσθετων μετρικών θα μπορούσε να εμπλουτίσει την αποτίμηση της συνολικής συμπεριφοράς των μοντέλων.

Συμπέρασμα

Η εργασία παρουσίασε μια συστηματική αξιολόγηση τεσσάρων προεκπαιδευμένων μοντέλων learned image compression της Compress AI χρησιμοποιώντας ενιαίο quality ladder, κοινή προ επεξεργασία και σταθερό πειραματικό πρωτόκολλο. Τα πειραματικά αποτελέσματα ανέδειξαν σημαντικές διαφορές στην απόδοση των μοντέλων με το cheng2020_attn να καταγράφει σταθερά την υψηλότερη ποιότητα ανακατασκευής τόσο σε PSNR όσο και σε MS-SSIM. Τα bmshj2018_hyperprior & mbt2018_mean εμφάνισαν ενδιάμεσες επιδόσεις, ενώ το bmshj2018_factorized αποτέλεσε τη γραμμή βάσης με τη χαμηλότερη συνολική ποιότητα.

Η ανάλυση της υπολογιστικής πολυπλοκότητας έδειξε ότι τα μοντέλα με πιο εξελιγμένες αρχιτεκτονικές συνοδεύονται από αυξημένο χρόνο κωδικοποίησης, επιβεβαιώνοντας το κλασσικό trade off μεταξύ ποιότητας και υπολογιστικού κόστους. Τα ευρήματα αυτά μπορούν να αξιοποιηθούν για την επιλογή codec ανάλογα με τις απαιτήσεις ενός πρακτικού συστήματος.

Συνολικά η εργασία ανέδειξε τον ρόλο της αρχιτεκτονικής στην επίδοση των learned codecs και τη σημασία ενοποιημένων πρωτοκόλλων αξιολόγησης. Η μεθοδολογία και τα αποτελέσματα μπορούν να αποτελέσουν βάση για μελλοντική έρευνα σε μεγαλύτερα datasets, σε πιο σύγχρονες αρχιτεκτονικές και σε περιβάλλοντα με μεγαλύτερες χρονικές και υπολογιστικές απαιτήσεις.

Βιβλιογραφία

[1] Bross, B., Wang, Y. K., Ye, Y., Liu, S., Chen, J., Sullivan, G. J., & Ohm, J. R. (2021). Overview of the versatile video coding (VVC) standard and its applications. IEEE Transactions on Circuits and Systems for Video Technology, 31(10), 3736-3764.

[2] M. Viitanen, J. Sainio, A. Mercat, A. Lemmetti, and J. Vanne, "From HEVC to VVC: the first development steps of a practical intra video encoder," IEEE Trans. Consumer Electron., vol. 68, no. 2, Jan. 2022, pp. 139-148.

[3] Uvg266, https://ultravideo.fi/uvg266.html

[4] Bégaint, J., Racapé, F., Feltman, S., & Pushparaja, A. (2020). Compressai: a pytorch library and evaluation platform for end-to-end compression research. arXiv preprint arXiv:2011.03029.

[5] CompressAI, https://interdigitalinc.github.io/CompressAI/intro.html

[6] Choi, H., Han, H., Rosewarne, C., & Racapé, F. (2025). CompressAI-Vision: Open-source software to evaluate compression methods for computer vision tasks. arXiv preprint arXiv:2509.20777.

[7] CompressAI Vision, https://interdigitalinc.github.io/CompressAI-Vision/

[8] https://r0k.us/graphics/kodak/